



Clasificación





Clasificación Binaria



Ejemplos

- Es spam o no es spam
- Transacciones fraudulentas
- Tumor benigno o maligno
- La persona pagará su préstamo de vuelta o no
- Los usuarios darán click en la publicidad
- Nombre de la persona en tu foto en Facebook

Clasificación


- Predice un label Y discreto.
- Se asignan nuevas observaciones en una clase a la cual probablemente corresponden.
 - Nos basamos en un modelo construido durante entrenamiento

Supervised Learning: Classification

training set

Observation #	Input image (X)	Label (Y)
1		"dog"
2		"cat"
3		"dog"
...
N		"dog"

test set

1		???
2		???

Clasificación binaria vs multclasificación


- Clasificación binaria
 - Tenemos clase negativa y clase positiva. El término es ambiguo

$$y \in \{0, 1\}$$

- Multclasificación
 - Muchas clases

$$y \in \{0, 1, 3, 4, 5\}$$

¿Cómo podemos resolver este problema con las herramientas que tenemos?



¿Cómo podemos resolver este problema con las herramientas que tenemos?

- Usamos regresión lineal como antes
- Ponemos un límite en el clasificador en 0.5
 - Si la hipótesis es mayor a 0.5, predecimos que $y=1$
 - Si la hipótesis es menor a 0.5, predecimos que $y=0$

$$h_{\theta} = \theta^T x$$

¿Cómo podemos resolver este problema con las herramientas que tenemos?

- Usamos regresión lineal como antes
- Ponemos un límite en el clasificador en 0.5
 - Si la hipótesis es mayor a 0.5, predecimos que $y=1$
 - Si la hipótesis es menor a 0.5, predecimos que $y=0$

$$h_{\theta} = \theta^T x$$

- ¿Qué pasaría si tenemos un tumor grande que no es maligno?

¿Cómo podemos resolver este problema con las herramientas que tenemos?

- Usamos regresión lineal como antes
- Ponemos un límite en el clasificador en 0.5
 - Si la hipótesis es mayor a 0.5, predecimos que $y=1$
 - Si la hipótesis es menor a 0.5, predecimos que $y=0$

$$h_{\theta} = \theta^T x$$

- ¿Qué pasaría si tenemos un tumor grande que no es maligno?
 - Se mueve toda la línea.

Regresión Logística

- Prestamos
- Si somos un banco, ¿damos un préstamo o no?
- Regresión logística calcula la probabilidad de que la aplicación sea fraude.


Regresión Logística

$$0 \leq h_{\theta}(x) \leq 1$$

$$h_{\theta}(x) = g(\Theta^T x)$$

Función sigmoideal o logística

$$S(x) = \frac{1}{1 + e^{-x}}.$$




Regresión Logística

$$0 \leq h_{\theta}(x) \leq 1$$

$$h_{\theta}(x) = g(\Theta^T x)$$

$$S(x) = \frac{1}{1 + e^{-x}}.$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\Theta^T x}}$$



Regresión Logística

- Objetivo: Encontrar los mejores parámetros Θ
- $h_{\theta}(x)$ = probabilidad estimada que $y = 1$ dado el input x
 - $P(y = 1 \mid x; \theta)$
 - $P(y = 0 \mid x; \theta) = 1 - P(y = 1 \mid x; \theta)$

$$h_{\theta}(x) = g(\Theta^T x) = P(y = 1 \mid X; \Theta)$$

Regresión Logística $h_{\theta}(x) = g(\Theta^T x) = P(y = 1|X; \Theta)$


- ¿En qué momento la función $g(z)$ es igual o mayor a 0.5?

Regresión Logística $h_{\theta}(x) = g(\Theta^T x) = P(y = 1|X; \Theta)$

- ¿En qué momento la función $g(z)$ es igual o mayor a 0.5?
- Cuando z es mayor o igual a 0.
- O: $\Theta^T x \geq 0$
- Cuando esto pasa predecimos que $y = 1$

Ejemplo


- $h_{\theta}(x) = g(-3 + x_1 + x_2)$
- ¿Cuándo predecimos que $y = 1$?



Ejemplo - Límite de decisión

- $h_{\theta}(x) = g(-3 + x_1 + x_2)$
- ¿Cuándo predecimos que $y = 1$?

- Esto se llama límite de decisión
 - Permite construir un límite sin tener dat



Límites no lineares

- Clasificación con círculo
- Como en regresión polinomial, podemos agregar términos de mayor grado.

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

Límites no lineares

- Como en regresión polinomial, podemos agregar términos de mayor grado.

$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

- Asumimos el siguiente valor para los parámetros

$$-1 + (x_1)^2 + (x_2)^2 \geq 0$$

$$(x_1)^2 + (x_2)^2 \geq 1$$

$$\Theta = \begin{bmatrix} -1 \\ 0 \\ 0 \\ 1 \\ 1 \end{bmatrix}$$



Modelo de Regresión Logística



Regresión Logística

- Tenemos un training set con m ejemplos

$$x = \begin{bmatrix} x_0 \\ x_1 \\ \dots \\ x_n \end{bmatrix}$$

$$x_0 = 1$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\Theta^T x}}$$

Función de pérdida


$$J(\theta_0, \theta_1, \dots, \theta_n) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J(\Theta) = \left(\frac{1}{m}\right) \sum_{i=1}^m \frac{1}{2} (h_{\theta}(x^i) - y^{(i)})^2 =$$


$$\left(\frac{1}{m}\right) \sum_{i=1}^m \text{loss}(h_{\theta}(x^i), y^{(i)})$$

Regresión Logística

- La anterior función no era convexa por la hipótesis (no linear)
 - La función sigmoide afecta



Loss Function



Gráfica de
logaritmo

- Como la anterior no funcionaba, podemos proponer una nueva que si sea convexa

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

- ¿Cómo se comporta cuando $y=1$?
- ¿Cómo se comporta cuando $y=0$?

Loss Function

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

$$\text{Cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1-y) \log(1 - h_{\theta}(x))$$

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

Esta fórmula se puede derivar de un concepto llamado maximum likelihood estimator. Es convexa para este problema

Gradient Descent

- Ajustamos los parámetros para minimizar la pérdida utilizando Gradient Descent

Repeat {

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(simultaneously update θ_j for
 $j = 0, \dots, n$)

}

- Lo único que cambia es la hipótesis

Algoritmos de Optimización

- No sólo está Gradient Descent
- Otros son
 - Conjugate Gradient
 - BFGG
 - L-BFGS
- Ventajas: No necesitas elegir learning rate y pueden ser más rápidos
- Desventajas: Más complejos - expertos de análisis numérico




Multclasificación



Ejemplos


- Etiquetado en correos
- Diagramas médicos
- Clasificación de clima

Multi-class classification




Clasificación uno vs todos

- Tenemos 3 clases
- ¿Ideas?



Clasificación uno vs todos

- Tenemos 3 clases
- ¿Ideas?
 - Podemos crear 3 clasificadores



Multclasificación

- Entrenamos un clasificador de regresión logística para cada clase i .
- Dada una nueva entrada, elegimos la clase i que maximice la hipótesis.

Otras técnicas

- Redes neuronales
- K-nearest neighbors
- Naive bayes
- Árboles de decisiones
- SVMs