




# Regularización




# Overfitting y Underfitting




# Overfitting y Underfitting


- Bias: Error introducido por aproximar un fenómeno real con un modelo simple.
- Variance: Qué tanto cambia el error en el testing set cuando cambiamos la información de entrenamiento



High bias  
(underfit)



“Just right”



High variance  
(overfit)

# Soluciones

- Reducir el número de features - pierdes información
  - Algoritmos de selección de modelo
  - Seleccionar qué features mantener
- Regularization
  - Reduce la magnitud de los parámetros.
  - Suele funcionar, en especial si todos los features importan.

# Regularización

- ¿Qué pasa si penalizamos que un parámetro en la función de error sea grande?

$$\min_{\theta} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + 1000 \theta_3^2 + 1000 \theta_4^2$$

# Regularización

- Los valores de los parámetros son más pequeños
- Se hace una hipótesis más sencilla
- Menos propenso a overfitting.

# Regularización para Regresión Linear con GD

$$J(\theta) = \frac{1}{2m} \left[ \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

$\min_{\theta} J(\theta)$

- ¿Cómo afecta Gradient Descent?

# Regularización para Regresión Lineal con EN

- Antes:

$$\Theta = (X^T X)^{-1} X^T y$$

- Ahora

$$\Theta = (X^T + \lambda \begin{bmatrix} 0 & & & \\ & 1 & & \\ & & 1 & \\ & & & 1 \end{bmatrix})^{-1} X^T y$$

- Se puede demostrar que siempre se invierte



# Regularización para Regresión Logística

$$J(\theta) = - \left[ \frac{1}{m} \sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \\ + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

- Se suma el término de regularización
- GD es exactamente igual